Hw3 report						
學號: 109062233	姓名:	蘇裕恆		繳交時間:		

Implementation:

1. Which algorithm do you choose in hw3-1?

在 3-1 裡面,我使用的是很 naïve 的 FLOYD-WARSHALL algorithm,並使用 pthread 作為相應的解法。因為主要來說都是 floyd – warshall 也比較好判斷。

- 2. How do you divide your data in hw3-2, hw3-3? 兩種方法都差不多,基本上就是把切成 64*64 的方塊並對其執行 block-floyd –warshall algorithm.
- 3. What's your configuration in hw3-2, hw3-3? And why? (e.g. blocking factor, #blocks, #threads)

我不知道 blocking factor 與 blocks 的差別,我選擇的是 64 作為 blocksize。

因為 gtx 1080 的配置,在 share memory 裡面總共有 49152 bytes. 我在 phase 3 裡面的實作需要三個 share memory block。同時,考慮到 warp 的性質是以 32 個資料作為單位,因此考慮 block 與 threads 接為 32 之倍數。

Thread 在 HW3-2 視為 32*32 · 在 HW3-3 為 16*64(原本 hw3-3 是參考我的第九版 code 所測計的 因此 thread 為 16*64(若變為 32*32 將有更好的 performance 但是因為已經全過了所以就沒有更改。)


4. How do you implement the communication in hw3-3? 我在 hw3-3 裡面,使用的是 openmp 作為 base (我不是很清楚這題想要問什麼 但如果是問 communication function 的話我使用的是 cudaMemcpy

```
if(i >= y_offset && i < y_offset + round ){
    cudaMemcpy(deviceDist[cpu_thread_id] + i * BlockSize * new_n , deviceDist[cpu_thread_id] + i * BlockSize * new_n , BlockSize * new_n * sizeof(int) , cudaMemcpyDeviceToHost
    // printf("in round %d there's an exchange from %d to %d \n" , i ,cpu_thread_id , !cpu_thread_id);
}</pre>
```

5. Briefly describe your implementations in diagrams, figures or sentences.

在 hw3-2 裡面,我總共 implement 了九個版本。因為後面的版本過於優化以至於基本上很難看懂,因此以下為第一版的 code。

總共有三個 phase,而一開始時候,會將 block 設為一個,並執行一開始使的計算



(a) Phase 1

概念上來說,就是將 naïve floyd-warshell 在小範圍內實作

```
v _global_ void phase1(int* Dist_d, int round_cnt, int new_n){
    __shared__ int store[BlockSize][BlockSize];
    int x_real = threadIdx.x + round_cnt * BlockSize;
    int y_real = threadIdx.y + round_cnt * BlockSize;
    int x = threadIdx.y;

/*if(x_real >= new_n || y_real >= new_n){
    __return;
    }*/
    store[x][y] = Dist_d[x_real * new_n + y_real];
    __syncthreads();
    for(int i = 0 ; i < BlockSize ; i++){
        store[x][y] = min(store[x][i] + store[i][y] , store[x][y]);
    __syncthreads();
    }
    Dist_d[x_real * new_n + y_real] = store[x][y];
}</pre>
```

注意在每次 run 完以後就必須像是 hw3-1 的實作一樣將 thread 同步 (因為 data 有 dependency)。

Pivot block	Pivot row	Pivot row
Pivot column		
Pivot column		

(b) Phase 2

```
global__ void phase2(int* Dist_d, int round_cnt, int new_n){
    __shared__ int store[BlockSize][BlockSize];
    __shared__ int vertical[BlockSize][BlockSize];
    __shared__ int herizonal[BlockSize][BlockSize];
    int x = threadIdx.x;
    int y = threadIdx.y;
    int block_num = blockIdx.y;
    int x_ver = threadIdx.x + round_cnt * BlockSize;
    int x_her = threadIdx.x + block_num * BlockSize;
    int y_ver = threadIdx.y + block_num * BlockSize;
    int y_her = threadIdx.y + round_cnt * BlockSize;
    if duplicate with the phase 1
    if(block_num == round_cnt) {
        return;
    }
    // since we calculate both vertical and herizonal at once ,we can't delete both given one doesn't fulfill
    store[x][y] = Dist_d[x_ver * new_n + y_her];
    herizonal[x][y] = Dist_d[x_ver * new_n + y_her];
    vertical[x][y] = Dist_d[x_ver * new_n + y_her];
    syncthreads();
    #pragma unroll 32
    for(int i = 0 ; i < BlockSize ; i++){
        vertical[x][y] = min( store[x][i] + vertical[i][y] , vertical[x][y]);
        herizonal[x][y] = min( herizonal[x][i] + store[i][y] , herizonal[x][y]);
    }
    Dist_d[x_ver * new_n + y_her] = herizonal[x][y];
    Dist_d[x_ver * new_n + y_ver] = vertical[x][y];
}
```

在 phase 二這邊我們使用一個(1, total_block_num) 作為 block 的形狀。同時,我的實作會同時將 row 跟 column 算完並回傳。基本上來說 vertical 就是 column。

```
void phase3(int* Dist_d, int round_cnt, int new_n){
 _shared__ int store[BlockSize][BlockSize];
 _shared__ int vertical[BlockSize][BlockSize];
_shared__ int herizonal[BlockSize][BlockSize];
int block_x = blockIdx.x;
int block_y = blockIdx.y;
if(block_x == round_cnt || block_y == round_cnt){
   return:
int x_real = block_x * BlockSize + x;
int y_real = block_y * BlockSize + y;
int x her = x real;
int y_her = round_cnt * BlockSize + y;
int x_ver = round_cnt * BlockSize + x;
int y_ver = y_real;
if(x_real >= new_n || y_real >= new_n){
store[x][y] = Dist_d[x_real * new_n + y_real];
vertical[x][y] = Dist_d[x_ver * new_n + y_ver];
herizonal[x][y] = Dist_d[x_her * new_n + y_her];
syncthreads();
#pragma unroll 32
for(int i = 0 ; i < BlockSize ; i++){
    store[x][y] = min(herizonal[x][i] + vertical[i][y] , store[x][y]);
Dist_d[x_real * new_n + y_real] = store[x][y];
```

在 phase3 這邊,我們將 row 跟 column 找出來,並透過 spec 給的方式做 reduction。注意: 此階段與上一階段接在每個 block 做同步。基本上就是找 pivot row 跟 column 來作為 base 並計算出 target 最小值。

至於 hw3-3、基本上作法與 hw3-2 類似,唯一的差別在於我將 phase 3 做了優化 (因為 profile 以後發現 phase3 占了 8.90%以上的運行時間,所以基本上優化都是由那邊進行的) 也有一部份是因為不需要過多的優化就可以將 hw3-3 全部通過,因此並沒有特別在做優化。優化方法如下:round 為每個 gpu 需要計算的點數 (行數)並且會有一個叫做 y_offset 來說從哪裡開始計算。最後,為了確保正確性,在計算之前都必須將 device data 做同步化來確保計算實的正確性。

我有不少優化,我將在之後——闡述。

Profiling Results (hw3-2)

Provide the profiling results of following metrics on the biggest kernel of your program using NVIDIA profiling tools. NVIDIA Profiler Guide.

我使用 p22k1 作為 profiling result 的 baseline。

	Min	Max	Average
occupancy	0.924393	0.925843	0.94892
sm efficiency	99.95%	99.97%	99.96%
shared memory load throughput	3232.6GB/s	3307.6GB/s	3272.7GB/s
shared memory store throughput	263.89GB/s	270.01GB/s	267.16GB/s
global load throughput	197.92GB/s	202.50GB/s	200.37GB/s
global store throughput	65.972GB/s	67.502GB/s	66.789GB/s

Experiment & Analysis & Discussion:

Explain how and why you do these experiments? Explain how you collect those measurements? Show the result of your experiments in plots, and explain your observations.


Methodology

- 1. System Spec (If you run your experiments on your own machine)
 Please specify the system spec by providing the CPU, RAM, storage
 and network (Ethernet / InfiniBand) information of the system.
 沒有,我使用的是 hades
- 2. Blocking Factor (hw3-2)


Observe what happened with different blocking factors, and plot the trend in terms of Integer GOPS and global/shared memory bandwidth. (You can get the information from profiling tools or manual) (You might want to check nyprof and Metrics Reference)

以下的圖表我將不會使用我的final version (因為他已經過度優化,無法隨意調整blocksize)因此 我會將整個結果建立在 version 7 (可以過到p23k1)而不是最終版本。 而已下的資訊是建立在c19.01


測量方法為先將 inst_int 數量除以 total time。Memory bandwidth 的部分則是將 load/store 的加 總在除以時間。



可以看到global memory因為blocking factor增大而遞減。推測是因為主要運算都是在shared memory,而我們在phase3主要只有將global的東西寫入與寫出,而blocking size變大會造成需要讀寫的次數變少進而造就這個結果。



可以看到並沒有很大的差別,這邊想不太太好的解釋方式。可以看到在雖然有增加,但之後就沒有太大的變化,推測是因為這個版本寫得沒有很好造成如此的現象。



但我們還是可以看到GOPS會因為blocking factor增加而增加。主要是因為shared memory的速度真的很快,因此在運算上如果一次般較大的資料過來,並不會成為bottleneck。因此可以看到隨著blocking factor增加而增加。

C. Optimization (hw3-2)

- 1. Shared memory
- 2. Coalesced memory access
- 3. No parathesis
- 4. Large blocking factor

其實主要來說,最好的方式就是shared memory好好調教。這邊就以我自己的版本為例,因為我無法像speculation那樣的寫 (我認為這不是很好劃分 像是shared memory的access pattern算不算一種coalesced memory access? (bank conflict)) 因此主要以我以下的為主。接下來主要講的phase 3

```
global_ void phase3(int* Dist_d, int round_cnt, int new_n){
    shared_ int store[BlockSize][BlockSize];
    shared_ int vertical[BlockSize][BlockSize];
    _shared_ int herizonal[BlockSize][BlockSize];
    int block_x = blockIdx.x;
    int block_y = blockIdx.y;
    int x = threadIdx.x;
    int y = threadIdx.y;
    int x = threadIdx.y;
    int x_neal = block_x * BlockSize + x;
    int y_real = block_y * BlockSize + x;
    int y_real = block_y * BlockSize + y;
    int x_her = x_real;
    int y_her = round_cnt * BlockSize + y;
    int y_her = round_cnt * BlockSize + x;
    int y_ver = y_real;
    if(x_real >= new_n || y_real >= new_n){
        return;
    }
    store[x][y] = Dist_d[x_real * new_n + y_real];
    vertical[x][y] = Dist_d[x_ler * new_n + y_ler];
    _syncthreads();
    #pragma unroll 32
    for(int i = 0; i < BlockSize; i++){
        store[x][y] = min(herizonal[x][i] + vertical[i][y], store[x][y]);
    }
    Dist_d[x_real * new_n + y_real] = store[x][y];
}</pre>
```

在一版中,我使用的技巧是沒有很嫻熟的share memory與判斷式。同時在input與output 有使用 coalesced memory access (這邊快了1.5倍左右)

在第二版中,我將一個thread需要運算的東西調整為原來的四倍,並同時將if else的statement拿掉 (因為不想要發生branch)這個版本變快了兩倍。同時為了更好的access memory因此將原本的(32,32)改為 (16,64)這樣的話就可以一次讀取 x,x+1,x+2,x+3 而不是 x,x+32,y+32)*y*y*y

+ x ...

這是第五版,因為3.4.5版本中最後總共improved了2~3倍左右,因此這邊統一說明。主要的猜測 shared memory access產生了bank conflict。所以就索性對調了一下access pattern(因此我將單純 store的行列對調)發現他整體會快了兩倍左右。

```
global_ void phase3(int *Dist d, int round cnt, int new_n){
    shared_ int store[BlockSize *BlockSize];
    shared_ int vertical[BlockSize *BlockSize];
    int block x - blockIdx.y;
    int block x - blockIdx.y;
    int x - threadIdx.y;
    int y real - block y * BlockSize *Y = BlockSize *Y;
    int x - threadIdx.y;
    int x - threadIdx.y;
    int x - threadIdx.y;
    int y real - block y * BlockSize * x;
    int y real - block y * BlockSize * y;
    int x - x real;
    int y new - x real;
    int y real - block y * BlockSize * y;
    int x - x real = block y * BlockSize * y;
    int x - x real = block y * BlockSize * y;
    int x - x real = block y * BlockSize * y;
    int x - x real = block y * BlockSize * y;
    int x - x real = block y * BlockSize * y;
    int x - x real = block y * BlockSize * y;
    int y ver - y real;
    int y real - block y * BlockSize * y;
    int y real - block y * BlockSize * y;
    int y real - block y * blockSize * y;
    int y real - block y * blockSize * y;
    int y real - block y * blockSize * y;
    int y real - block y * blockSize * y;
    int y real - block y * blockSize * y;
    int y real - block y * blockSize * y;
    int y real - block y * blockSize * y;
    int y real - block y * blockSize * y;
    int y real - block y * blockSize * y;
    int y real - block y * blockSize * y;
    int y real - block y * blockSize * y;
    int y real - block y * blockSize * y;
    int y real - block y * blockSize * y;
    int y real - block y * blockSize * y;
    int y real - block y * blockSize * y;
    int y real - block y * blockSize * y;
    int y real - block y * block y
```

Version 7這邊是將blockSize改為原本的 (32,32) 來測試效果。發現access解決bank conflict又可以增加兩倍的時間。

Version 9 (差了一筆) 是一直測試access pattern。並發現用(16,64) 可以加速不少 (兩倍) 因此就在這個情況下一直在做input/output的speed up。

```
| global_void phase3(int* Dist_d, int round_cnt, int new_n){
| shared_int store[BlockSize * BlockSize);
| shared_int vertical[BlockSize * BlockSize);
| shared_int vertical[BlockSize * BlockSize);
| int x - browaldia.x;
| int y -
```

最後一個version最特別,因為我在試的時候發現其實 (x << 6) 會比 x*64 還要慢。將原本 y*blockSize + x 變成 temp並將全部改成temp不會加速多少。因此嚴重懷疑parathesis在gpu computing裡面造成的速度下降。 因此,就索性將原本很慢的 (32,32) 來使用並直接使用 數字


來代表access block,最終又增快了 1.2 倍。((hurray))

因此我不會對optimization作圖 (因為太難界定甚麼東西會快幾倍了)。而且在programming中都是可能一次改一小部分,並沒有所謂一次將整個shared memory都改道到完善。

Weak scalability:

我的作法只有將phase 3 分段,因為floyd-warshell是一個dependency很高的算法,因此每次都會需要將資料傳給對方以確保答案的重要性。因此,大概估了一下我的scalability是1.7倍左右。

Time Distribution:



Experience & Conclusion

- 1. What have you learned from this homework?
 Cuda programming 好像在通靈。有時候改一下就發現突然變快了。有時候改一典認為會變快的東西結果竟然變慢了。同時,要考慮蠻 gpu 硬體架構,這是之前軟體課沒有教過的東西,其實還蠻新奇的。
- 2. FeedBack: spec 其實用字有點奇怪 像是 block factor 與 block 差異點在哪裡? 還有一些 communication? 其實不太懂